

Informe Técnico: Análisis Exploratorio de Datos (EDA) – Empresa ComercioYA

Autora: Bernardita Ortega

Fuente de Base de Datos: E-commerce User Behavior and Transaction Data

<https://www.kaggle.com/datasets/ziya07/e-commerce-user-behavior-and-transaction-dataset>

GitHub:

<https://github.com/bernimof/TD-CsdeDatos/tree/main/M4-ABP-Analisis-Exploratorio-de-Datos-para-Decisiones-Comerciales>

1. Introducción y Contexto

La empresa ComercioYA, dedicada a las ventas en línea, requiere comprender el comportamiento histórico de sus clientes (compras, visitas, montos y reseñas) para optimizar su estrategia de ventas y marketing. El objetivo de este informe es aplicar técnicas de EDA para detectar patrones, relaciones y valores atípicos que sustenten decisiones estratégicas basadas en evidencia.

2. Metodología y Preparación

Para el análisis se utilizaron las librerías estándar de Python: pandas para manipulación de datos, numpy para cálculos numéricos, matplotlib/seaborn para la visualización y Statsmodels: Para el ajuste y resumen del modelo de Regresión Lineal.

El proceso se dividió en las siguientes etapas técnicas:

- Análisis Inicial de Datos (IDA): Verificación de formatos, detección de valores nulos, duplicados e inconsistencias.
- Clasificación de Variables: Identificación de datos cuantitativos (montos, visitas) y categóricos (productos, zonas).
- Estadística Descriptiva: Cálculo de medidas de tendencia central y dispersión.
- Modelado: Aplicación de regresión lineal para predecir el comportamiento del gasto.

3. Hallazgos del Análisis Exploratorio (EDA)

a. Estadística Descriptiva


Se calcularon las métricas fundamentales para cada variable numérica relevante del negocio:

- Tendencia Central: Media, mediana y moda para entender el valor promedio de compra.
- Dispersión: Rango, varianza y desviación estándar para medir la consistencia de las ventas por región.
- Posición: Determinación de cuartiles y percentiles para segmentar a los clientes según su nivel de gasto.


Visualizaciones generadas:

- Histogramas: Para observar la frecuencia de las ventas y la distribución de las visitas.

Histogramas de Variables Numéricas




- Boxplots (Diagramas de caja): Utilizados para detectar visualmente valores atípicos (outliers) que representan compras inusualmente altas o bajas.




b. Análisis de Correlación - Relaciones y Correlaciones

Se aplicó el coeficiente de correlación de Pearson para cuantificar la fuerza y dirección de la relación entre variables.

- Hallazgo clave: Se identificó una fuerte correlación entre la frecuencia de compra (Frequency) y el gasto total (Monetary). Por lo tanto, a mayor número de compras, mayor es el gasto total.
- Interacción: Existe una correlación significativa entre el número de sesiones (Session_Count), los clics y el gasto final (Monetary), sugiriendo que los clientes más activos digitalmente generan más ingresos.



- Visualización: Se utilizaron scatterplots (gráficos de dispersión) para observar tendencias entre el tiempo pasado en la tienda y la cantidad de productos vistos.



4. Modelado Predictivo

a. Regresión Lineal Simple

Siguiendo los requerimientos, se ajustó un modelo de regresión lineal para predecir el gasto de los clientes.

- El modelo simple indica que la variable Frequency es estadísticamente significativa ($p < 0.001$).
- El coeficiente estimado sugiere que por cada compra adicional, el gasto total (Monetary) aumenta en aproximadamente 87 unidades monetarias.
- El modelo presenta un R^2 cercano a 0.75, lo que indica que el 75% de la variabilidad del gasto total es explicada por la frecuencia de compra.

b. Regresión Lineal Múltiple

Se ajustó un modelo de regresión lineal múltiple para predecir el valor de vida del cliente (Monetary) a partir de Frequency, Session_Count y Clicks.

Ecuación del Modelo Resultante:

$$\text{Gasto(Monetary)} = -828.81 + (26.57 \times \text{Frequency}) + (21.45 \times \text{Session_Count}) + (0.66 \times \text{Clicks})$$

Interpretación de Coeficientes:

- Frequency: Por cada compra adicional, el gasto estimado aumenta en 26.57 USD.
- Session_Count: Cada sesión de navegación adicional incrementa el gasto en 21.45 USD.
- Clicks: Cada clic extra aporta 0.66 USD al valor proyectado del cliente.

La significancia de cada predictor se evaluó mediante sus p-values ($\alpha = 0.05$).

El desempeño se reportó con R^2 , R^2 ajustado, MSE y MAE.

5. Conclusiones y Recomendaciones Estratégicas

El análisis exploratorio de datos y la regresión lineal mostraron que existe una fuerte relación entre la frecuencia de compras y el gasto total. Se recomienda a la empresa:

- Fomentar la Recurrencia: Dado que la frecuencia de compra tiene el mayor impacto directo en el gasto, se recomienda implementar programas de lealtad.
- Optimizar la Interacción: El número de sesiones es un predictor clave; mejorar la experiencia de usuario (UX) para aumentar las visitas impactará directamente en la facturación.
- Gestión de Outliers: Es necesario investigar los valores atípicos en devoluciones y abandono de carrito para reducir pérdidas operativas.
- Monitoreo del Modelo: Se recomienda reentrenar periódicamente el modelo para evitar la degradación del desempeño ante cambios en el comportamiento del consumidor.