

INFORME TÉCNICO ABP 6: APRENDIZAJE DE MÁQUINA SUPERVISADO APLICADO A LA PREDICCIÓN DE GASTO EN CLIENTES E-COMMERCE

Autora: Bernardita Ortega

GitHub:

https://github.com/bernimof/TD_CsdeDatos/tree/main/M6_ABP_Aprendizaje_de_maquina_supervisado

SITUACIÓN INICIAL

Unidad solicitante: Departamento de Analítica Comercial de una empresa de e-commerce.

La empresa busca optimizar su estrategia de marketing personalizando ofertas según el perfil de cada usuario. Para lograrlo, necesita construir un modelo de aprendizaje de máquina capaz de predecir el monto promedio de compra de un cliente en función de características demográficas y de comportamiento en el sitio web.

OBJETIVO

Diseñar e implementar un **modelo predictivo de regresión que permita estimar el monto de compra esperado por un cliente**. Se utilizan datos históricos, técnicas de preprocesamiento, validación cruzada, algoritmos de regresión y optimización hasta llegar a un modelo final funcional y confiable.

DESCRIPCIÓN DEL DATASET

El dataset contiene 1.000 registros y 11 variables. Se detectaron valores nulos en 6 variables.

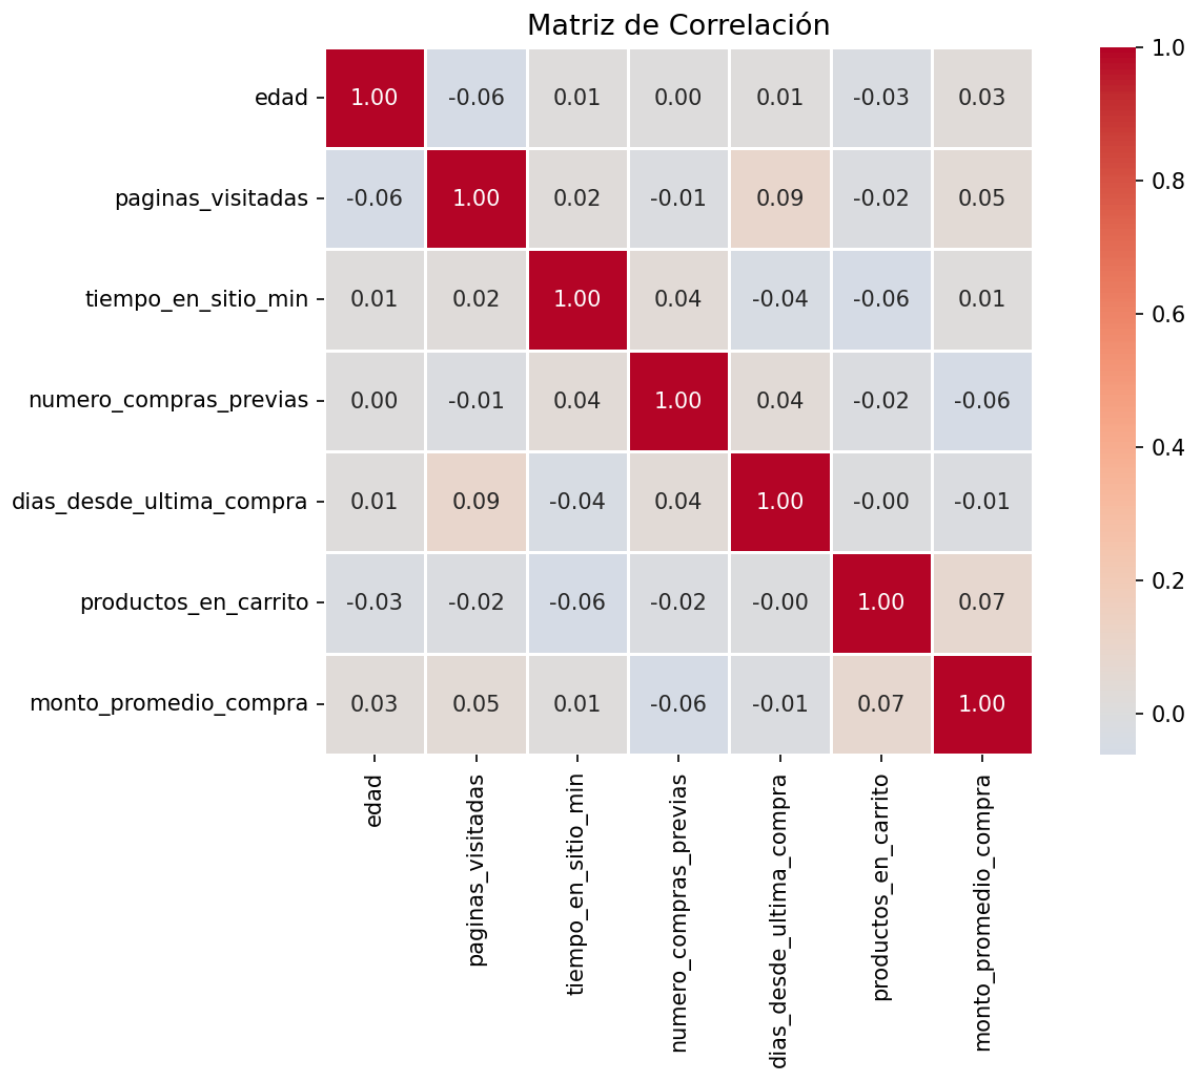
IDENTIFICACIÓN DE VARIABLES

- Variable objetivo (y): 'monto_promedio_compra' (entre 15.118–500.990 pesos), **lo que confirma el problema como una regresión supervisada: se predice un valor numérico, no una categoría.**

- Variables predictoras (X):

Nombre	Variable	Tipo	Descripción
edad	Númerica	Demográfica	Edad del cliente (18-81 años)
genero	Categórica	Demográfica	Género del cliente (Femenino o Masculino)
zona	Categórica	Demográfica	Zona geográfica (Norte, Sur, Centro, Oeste o Este)
nivel_educacion	Categórica	Demográfica	Nivel educativo alcanzado (Colegio/Liceo, Universitario o Posgrado)
paginas_visitadas	Númerica	Comportamiento Web	Cantidad de páginas visitadas por sesión (1-49 páginas)
tiempo_en_sitio_min	Númerica	Comportamiento Web	Tiempo total en el sitio en minutos (5-240 minutos)
numero_compras_previas	Númerica	Historial de Compra	Cantidad de compras históricas (0-29 compras previas)
dias_desde_ultima_compra	Númerica	Historial de Compra	Días de la última compra (0-180 días)
productos_en_carrito	Númerica	Comportamiento Web	Cantidad de productos en carrito (0-9 items)
uso_cupones	Binaria	Comportamiento Compra	1 = usó cupón, 0 = no usó
tipo_dispositivo	Categórica	Demográfica	Dispositivo de acceso (Celular, Computador o Tablet)

MATRIZ DE CORRELACIÓN



Ninguna variable numérica tiene correlación fuerte con ‘monto_promedio_compra’. Los valores son todos cercanos a 0, lo que anticipa un bajo R^2 en la Regresión Lineal y sugiere relaciones no lineales, justificando el uso de modelos más complejos.


PREPROCESAMIENTO

TRATAMIENTO DE VALORES NULOS

Se detectaron **valores nulos en 6 variables**: 'zona', 'nivel_educacion', 'tiempo_en_sitio_min', 'numero_compras_previas', 'dias_desde_ultima_compra' y 'tipo_dispositivo'. Se utilizó SimpleImputer con estrategia mediana para variables numéricas y moda para variables categóricas.

TRATAMIENTO DE OUTLIERS

Se aplicó el método IQR y el boxplot para detectar outliers. No se detectaron outliers en las variables predictoras. Pero si en la variable a predecir de 'monto_promedio_compra'. Estos se conservaron deliberadamente: un gasto de \$500.990 es un dato real, no un error de medición. Los tres eran de clientes de alto 'monto_promedio_compra'. Eliminarlos o Winsorizarlos sesgaría el modelo hacia clientes de gasto medio, impidiendo predecir correctamente a clientes de alto valor.



CODIFICACIÓN DE VARIABLES CATEGÓRICAS

Las variables 'genero', 'zona', 'nivel_educacion' y 'tipo_dispositivo' fueron codificadas con variables dummies para evitar multicolinealidad. Dataset resultante: 17 características.

ESCALAMIENTO

Se eligió StandardScaler (media=0, std=1) sobre las 6 variables numéricas continuas, porque es más robusto frente a los outliers detectados, a diferencia de MinMaxScaler que es sensible a estos. La variable 'uso_cupones' no fue escalada por ser binaria (0/1).

NIVEL DE AJUSTE DEL MODELO Y VALIDACIÓN CRUZADA

ERRORES DE ENTRENAMIENTO Y PRUEBA

Se entrenó un modelo de Regresión Lineal base para comparar errores en entrenamiento y prueba:

- MSE: Muy alto por el efecto de los outliers en 'monto_promedio_compra'.
- RMSE: El modelo se aleja en promedio \$57.636 del valor real.
- MAE: Métrica más representativa dado los outliers en Y. Error promedio de \$47.866 por predicción.
- R^2 (Test) de 0.0046: el modelo explica menos del 1% de la varianza del gasto.

IDENTIFICACIÓN DE SOBREAJUSTE Y SUBAJUSTE

Métrica	Resultado Train	Resultado Test
Raíz del Error Cuadrático Medio (RMSE)	56333.21	57636.11
Coefficiente de Determinación (R^2)	0.0136	0.0046

Ambos errores están altos con brecha mínima entre train y test, por lo que, hay un subajuste. Indicando que la Regresión Lineal es un modelo demasiado simple para capturar los patrones del dataset (falta de capacidad).

VALIDACIÓN CRUZADA K-FOLD (K=5)

La validación cruzada K-Fold (K=5) arrojó RMSE promedio de $\$57.555 \pm \2.874 . La baja desviación estándar entre folds confirma que el modelo es estable — los resultados no dependen de una partición particular. Pero el R^2 promedio de -0,028343 indica que no aprende nada útil. Esto justifica avanzar hacia modelos más complejos.

REGRESIÓN

COMPARACIÓN: REGRESIÓN LINEAL VS POLINOMIAL

	MAE	MSE	RMSE	R ²
Modelo				
Lineal — Train	47378.318862	3.173431e+09	56333.213983	0.013613
Lineal — Test	47866.194880	3.321921e+09	57636.106665	0.004606
Polinomial — Train	42584.895540	2.576010e+09	50754.412929	0.199307
Polinomial — Test	51760.999527	4.225747e+09	65005.742332	-0.266221

Ajuste (train vs test):


- Lineal: MAE train \$47.378 vs test \$47.866 — diferencia mínima. Bien ajustado, pero con subajuste.
- Polinomial: MAE train \$42.584 vs test \$51.760 — diferencia notable. Sobreajuste.

Precisión (qué modelo predice mejor):

- El lineal es más consistente entre train y test, aunque con bajo poder predictivo.
- El polinomial mejora en train (R^2 0,19), pero empeora en test (R^2 -0,27). La complejidad extra no ayuda a generalizar.

El MSE da números enormes, demostrando el impacto de los outliers en Y al elevar los errores al cuadrado. El RMSE al ser su raíz cuadrada, devuelve el error a la unidad original (\$), siendo más interpretable: el modelo lineal se equivoca en promedio \$56.333 en train y \$57.636 en test.

INTERPRETACIÓN DE COEFICIENTES — REGRESIÓN LINEAL



Cada coeficiente indica cuánto aumenta/disminuye 'monto_promedio_compra' por cada unidad adicional de esa variable, manteniendo las demás constantes. El coeficiente positivo (azul) incrementa el gasto, el coeficiente negativo (rojo) lo reduce y cercano a 0 prácticamente no influye.

ALGORITMOS DE CLASIFICACIÓN

¿POR QUÉ CLASIFICACIÓN NO ES ADECUADO?


La variable objetivo 'monto_promedio_compra' es un valor numérico continuo. Usar clasificación implicaría discretizarla artificialmente en categorías (Bajo/Medio/Alto), con dos consecuencias: pérdida de información (predecir 'Alto' no dice si el gasto es \$200.000 o \$500.000) y métrica inadecuada (accuracy no captura qué tan lejos estuvo la predicción del valor real).

RESULTADOS DE KNN CLASIFICADOR (K=5)

Para demostrarlo empíricamente, se implementó un KNN Clasificador (k=5) con categorías Bajo/Medio/Alto y se comparó contra la Regresión Lineal:


Accuracy KNN Clasificador (k=5): 0.3650				
Reporte de clasificación:				
	precision	recall	f1-score	support
Alto	0.28	0.36	0.31	53
Bajo	0.33	0.36	0.34	61
Medio	0.50	0.37	0.43	86
accuracy			0.36	200
macro avg	0.37	0.36	0.36	200
weighted avg	0.39	0.36	0.37	200

Se obtiene una Exactitud (Accuracy) de 0.365, por lo que, solo acierta el 36.5% de los casos. La peor Precisión (Precision) es Alto (0.28) — el modelo prácticamente no identifica a los clientes de alto valor.



En la diagonal de la Matriz de Confusión están los aciertos (22, 32, 19) y fuera de la diagonal están los errores entre la categoría real (filas) y la categoría predicha (columnas). Por ejemplo, en la categoría 'Bajo' existen 61 casos reales y predijo bien 22, confundió 16 con 'Medio' y 23 con 'Alto', equivocándose en más de la mitad. Por lo tanto, el modelo no logra distinguir bien ninguna categoría — los errores están distribuidos de forma casi uniforme en todas las celdas, lo que indica que el clasificador prácticamente adivina.

COMPARACIÓN VISUAL: REGRESIÓN VS CLASIFICACIÓN



En la Regresión Lineal, los puntos se concentran entre \$80.000 y \$120.000 sin importar el valor real, lo que confirma el subajuste: el modelo tiende a predecir siempre cerca del promedio y no logra seguir la línea diagonal roja (predicción perfecta).

En el KNN Clasificador se ven claramente las 3 líneas horizontales. Todos los clientes predichos como "Alto" quedan en la misma fila, sin importar si su monto real es \$20.000 o \$400.000. Significa que clientes de gasto bajo quedan clasificados como alto, el peor error posible para el negocio. Esto demuestra visualmente la pérdida de información al utilizar este modelo.

Aunque la regresión lineal tampoco predice bien (subajuste), al menos intenta estimar el monto exacto. La clasificación directamente colapsa toda la información en 3 etiquetas, haciendo imposible distinguir entre un cliente de \$71.000 y uno de \$149.000 — ambos son simplemente "Medio".

MÉTRICAS DE DESEMPEÑO

TABLA COMPARATIVA — REGRESIÓN LINEAL VS POLINOMIAL

Tabla comparativa de Métricas				
	MAE	MSE	RMSE	R ²
Modelo				
Regresión Lineal	\$47,866	3,321,920,791	\$57,636	0.0046
Regresión Polinomial	\$51,761	4,225,746,536	\$65,006	-0.2662

La Regresión Lineal supera al modelo Polinomial en todas las métricas:

- **MAE:** El modelo lineal se equivoca \$47.866 por predicción. El polinomial se equivoca en promedio \$3.895 más por predicción.
- **MSE:** Los valores enormes (3.3 y 4.2 mil millones) confirman el impacto de los outliers en Y al elevar los errores al cuadrado.
- **RMSE:** Al penalizar errores grandes, un RMSE alto indica que el modelo comete errores graves en algunos clientes. El polinomial comete errores más graves.
- **R²:** Un R² cercano a 0 indica que el modelo no está explicando la varianza del gasto. El polinomial explica negativamente la varianza, es decir, predice peor que usar el promedio como predicción fija.

OPTIMIZACIÓN DEL MODELO

INGENIERÍA DE CARACTERÍSTICAS (FEATURE ENGINEERING)

Se crearon 4 nuevas variables que combinan información de varias columnas, capturando relaciones que las variables originales solas no expresan:

- engagement = paginas_visitadas × tiempo_en_sitio (nivel de interés real del cliente)
- ratio_conversion = compras_previas / (paginas + 1) (eficiencia de conversión por visita)
- recencia_inv = 1 / (dias_ultima_compra + 1) (clientes recientes tienen más valor — RFM)
- carrito_cupon = productos_carrito × uso_cupones (patrón combinado de comportamiento)

Comparación — Regresión Lineal CON y SIN ingeniería de características				
	MAE	MSE	RMSE	R ²
Modelo				
Sin ingeniería (base)	\$47,866	3,321,920,791	\$57,636	0.0046
Con ingeniería	\$47,698	3,306,476,043	\$57,502	0.0092

Las cuatro nuevas variables generaron una mejora leve en el modelo:

- MAE: bajó → el error promedio se redujo \$168 por predicción.
- RMSE: bajó → menos errores graves.
- R²: aumentó → el modelo duplicó su capacidad explicativa, aunque sigue siendo muy baja.

La ingeniería de características ayudó, pero si el algoritmo inicial tiene limitaciones estructurales (como la regresión lineal ante patrones no lineales), la mejora tiene un techo. Esto justifica avanzar hacia GridSearchCV con regularización y Gradient Boosting.

REGULARIZACIÓN: RIDGE Y LASSO

Se aplicó GridSearchCV sobre Ridge para encontrar el alpha óptimo, y se comparó con Lasso probando alphas de 0.01 a 1000. Ambos modelos alcanzaron su mejor desempeño con alpha = 1000 — la regularización más fuerte probada. Lasso superó levemente a Ridge porque lleva coeficientes a 0 exacto, actuando como selección automática de variables en un dataset con muchas variables de baja correlación.

					Lasso — Comparación por alpha				
					MAE	MSE	RMSE	R ²	
					Modelo				
					Lasso (α=0.01)	\$47,698	3,306,474,768	\$57,502	0.0092
					Lasso (α=0.1)	\$47,698	3,306,463,296	\$57,502	0.0092
					Lasso (α=1)	\$47,698	3,306,348,466	\$57,501	0.0093
					Lasso (α=10)	\$47,696	3,305,325,611	\$57,492	0.0096
					Lasso (α=100)	\$47,700	3,299,241,709	\$57,439	0.0114
					Lasso (α=1000)	\$47,686	3,274,697,007	\$57,225	0.0188
					Ridge Optimizado — Test	\$47,748	3,288,824,906	\$57,348	0.0145

ALGORITMOS DE BOOSTING

GRADIENTBOOSTINGREGRESSOR

Se entrenó un GradientBoostingRegressor base y luego se optimizó con GridSearchCV evaluando 24 combinaciones de hiperparámetros.

GradientBoostingRegressor – Resultados:				
	MAE	MSE	RMSE	R ²
Modelo				
GB Base — Train	\$26,084	963,472,395	\$31,040	0.7005
GB Base — Test	\$48,370	3,176,605,970	\$56,361	0.0481
GB Optimizado — Test	\$46,883	2,981,842,928	\$54,606	0.1065

El modelo base ($n_{\text{estimators}}=200$, $\text{max_depth}=4$) mostró sobreajuste severo (R^2 Train 0.70 vs Test 0.048). GridSearchCV eligió hiperparámetros más simples (menos árboles, menor profundidad) que redujeron la brecha y mejoraron la generalización.

Así el modelo optimizado que con los siguientes hiperparámetros: $\text{learning_rate}=0.05$, $\text{max_depth}=3$, $n_{\text{estimators}}=100$, $\text{subsample}=1.0$. Con $R^2 = 0.1065$, el GradientBoosting Optimizado es el mejor modelo del proyecto — explica el 10.65% de la varianza del gasto, superando ampliamente a todos los modelos lineales evaluados (máximo $R^2 = 0.0197$ con Lasso).

COMPARACIÓN FINAL DE TODOS LOS MODELOS (TEST)


Tabla Comparativa de los Modelos Aplicados (Test)				
	MAE	MSE	RMSE	R ²
Modelo				
Reg. Lineal	\$47,866	3,321,920,791	\$57,636	0.0046
Reg. Polinomial	\$51,761	4,225,746,536	\$65,006	-0.2662
Ridge ($\alpha=1000$)	\$47,748	3,288,824,906	\$57,348	0.0145
Lasso ($\alpha=1000$)	\$47,686	3,274,697,007	\$57,225	0.0188
Gradient Boosting	\$46,883	2,981,842,928	\$54,606	0.1065

Como se aprecia en la tabla, Gradient Boosting es el mejor modelo en todas las métricas:

- MAE más bajo (\$46.883) → menor error promedio por predicción.
- MSE más bajo (2.981.842.928) → menor impacto de outliers.
- RMSE más bajo (\$54.606) → menos errores graves.
- R^2 más alto (0.1065) → único modelo que supera el 10% de varianza explicada.

Aunque el R^2 general sigue siendo moderado, esto refleja que el gasto en e-commerce es difícil de predecir solo con variables demográficas y de comportamiento básico. Gradient Boosting es claramente la mejor herramienta disponible con estos datos.

IMPORTANCIA DE VARIABLES



De las 21 variables, la 'edad', 'paginas_visitadas' y 'engagement' son las variables más influyentes.

Las cuatro nuevas variables de ingeniería de características aparecen en:

- 'engagement' → 3º lugar
- 'ratio_conversion' → 5º lugar
- 'recencia_inv' → 6º lugar
- 'carrito_cupon' → 10º lugar

Las variables de 'zona_Norte', 'zona_Este', 'zona_Sur', 'tipo_dispositivo_Tablet' y 'nivel_educacion_Posgrado' tienen barras casi invisibles, por lo que, prácticamente no influyen en el gasto.

Para el negocio, los esfuerzos de personalización deberían focalizarse en la 'edad del cliente' y su 'nivel de engagement' (páginas visitadas y tiempo en sitio), ya que son las señales más fuertes para predecir cuánto va a gastar.

VENTAJAS Y LIMITACIONES DEL ENFOQUE ENSAMBLE (ENSEMBLE)

Ventajas:

- Alta precisión: genera modelos altamente precisos gracias a su naturaleza secuencial y correctiva.
- Identificación de patrones complejos: captura relaciones no lineales e interacciones entre variables.
- Flexibilidad: admite ajuste de numerosos hiperparámetros que influyen en el rendimiento.
- Importancia de características: permite visualizar la importancia relativa de cada variable predictora.

Limitaciones:

- Sensibilidad al ruido: puede sobreajustar si no se regulariza adecuadamente.
- Mayor tiempo de entrenamiento: método secuencial, no se beneficia del paralelismo.
- Requiere regularización: su aplicación debe incluir estrategias de regularización y validación cruzada.

CONCLUSIÓN Y MODELO FINAL ELEGIDO

Tras comparar todos los modelos, el GradientBoostingRegressor optimizado es el modelo final seleccionado por las siguientes razones:

- Mejor desempeño en métricas objetivas: menor RMSE (\$54.606) y mayor R^2 (0.1065) sobre el conjunto de prueba.
- Captura de no linealidades: modela comportamientos complejos que los modelos lineales no capturan.
- Robustez: validación cruzada K-Fold mostró baja varianza entre folds (modelo estable).
- Importancia de características: permite identificar que la 'edad' y el 'engagement' (páginas visitadas × tiempo en sitio) son las señales más fuertes.

El modelo GradientBoostingRegressor puede utilizarse para predecir el monto estimado de compra de cada cliente y así segmentar clientes por gasto esperado, personalizar ofertas, umbrales de descuento y estrategias de retención basadas en datos. Se recomienda focalizar los esfuerzos de personalización en la 'edad del cliente' y su 'nivel de engagement'. Se sugiere reentrenar mensualmente incorporando nuevos datos transaccionales.