

INFORME FINAL ABP 7: APRENDIZAJE DE MÁQUINA NO SUPERVISADO APLICADO A UN SEGMENTADOR INTELIGENTE DE CLIENTES MINORISTAS

Autora: Bernardita Ortega

GitHub:

<https://github.com/bernimof/TD-CsdeDatos/tree/main/M7-ABP-Aprendizaje-de-maquina-no-supervisado>

Dataset: Archivo Train.csv de Customer Segmentation Classification — Kaggle (kaushiksuresh147).

<https://www.kaggle.com/datasets/kaushiksuresh147/customer-segmentation>

SITUACIÓN INICIAL

Unidad solicitante: Departamento de Inteligencia de Negocios de "Retail Insights S.A.".

Retail Insights S.A. es una consultora que trabaja con múltiples cadenas de tiendas físicas y e-commerce. Uno de sus clientes busca entender mejor el comportamiento de sus clientes para personalizar campañas de marketing. Actualmente, solo se utiliza información básica como edad o historial de compras totales, lo cual no permite generar estrategias diferenciadas ni identificar segmentos ocultos.

Se solicita aplicar técnicas de machine learning no supervisado para realizar un modelo de segmentación de clientes que sea útil, visualmente entendible y escalable a nuevos datos.

OBJETIVO

Desarrollar un sistema de segmentación de clientes a partir de un dataset no etiquetado utilizando técnicas de aprendizaje no supervisado. El objetivo es aplicar algoritmos de clusterización y reducción dimensional para identificar grupos de comportamiento relevantes, visualizarlos y evaluar los hallazgos para su aplicación futura.

Este proyecto busca responder a la necesidad de identificar patrones ocultos en los datos de clientes y presentar insights que permitan la toma de decisiones informadas en campañas de retención, fidelización y ventas cruzadas.

LECCIÓN 1 - FUNDAMENTOS DEL APRENDIZAJE NO SUPERVISADO

El aprendizaje no supervisado es una rama del machine learning donde el modelo trabaja con datos sin etiquetas. El algoritmo descubre patrones, estructuras o agrupaciones internas en los datos por sí solo.

Las principales tareas son:

- Clusterización: agrupar elementos similares.
- Reducción de dimensionalidad: reducir la cantidad de variables sin perder información.
- Análisis de reglas de asociación: busca reglas o correlaciones dentro de grandes bases de datos.
- Detección de anomalías: identificar eventos inusuales o datos que se desvían significativamente del comportamiento general.

Es importante seleccionar la técnica adecuada según el tipo de problema, el objetivo del análisis y la naturaleza de los datos. De esta forma, se garantiza que el modelo no solo sea útil, sino también interpretable y eficiente.

Tipo de Tarea	Técnica	Descripción	Ejemplos de Casos Reales
Clusterización	K-Means	Agrupamiento basado en centroides	Segmentación de clientes, análisis de comportamiento, agrupamiento de imágenes, procesamiento de lenguaje natural (NLP - agrupamiento de grandes volúmenes de documentos o noticias por temática), análisis genómico y clasificación de especies.
	DBSCAN	Agrupamiento basado en la densidad de los puntos.	
	Clustering Jerárquico (Hierarchical clustering)	Creación de jerarquías de grupos mediante dendrogramas	
	Mezcla Gaussiana (GMM)	Modelado probabilístico de clústeres	
Reducción de Dimensionalidad	PCA (Análisis de Componentes Principales)	Técnica lineal para maximizar la varianza	Visualización de datos, compresión, procesamiento de lenguaje natural (NLP).
	t-SNE (t-Distributed Stochastic Neighbor Embedding)	Proyecta datos de alta dimensión preservando las relaciones de proximidad locales; es decir, asegura que los puntos que están cerca en el espacio original permanezcan cerca en la visualización.	
	UMAP (Uniform Manifold Approximation and Projection)	Al igual que t-SNE, busca reducir dimensiones, pero se destaca por ser significativamente más rápido. UMAP	

Tipo de Tarea	Técnica	Descripción	Ejemplos de Casos Reales
		logra un mejor equilibrio entre la preservación de la estructura local y la global de los datos.	
Técnicas de Asociación	Algoritmo Apriori	Utilizado para extraer reglas de asociación significativas.	Reglas de co-ocurrencia (ej. Análisis de Carrito de Supermercado: clientes que compran pan también compran mantequilla). Sistemas de Recomendación.
	FP-Growth	Identifica conjuntos de elementos frecuentes y genera reglas de co-ocurrencia en grandes bases de datos	
Detección de anomalías	Isolation Forest	Funciona identificando observaciones que se desvían del comportamiento normal	Ciberseguridad, fraudes financieros, fallas industriales, mantenimiento predictivo.
	Autoencoder	Es una arquitectura de red neuronal que aprende representaciones comprimidas de los datos mediante un proceso de codificación y decodificación	

LECCIÓN 2 - TÉCNICAS DE CLUSTERIZACIÓN

ESCENARIOS DE APLICACIÓN

- **Marketing:** Segmentación de clientes basada en comportamientos de compra para crear campañas personalizadas.
- **Biología:** Agrupamiento de genes o especies con características similares y análisis genómico para investigación médica.
- **Procesamiento de Lenguaje Natural (NLP):** Organización de grandes volúmenes de documentos, noticias o comentarios por temáticas sin entrenamiento previo.
- **Ingeniería:** Agrupación de sensores con lecturas similares para facilitar la detección de fallas en sistemas industriales.
- **Astronomía:** Clasificación de objetos celestes según sus propiedades físicas y espectrales.

VENTAJAS Y DESVENTAJAS

Ventajas	Desventajas
• Permite trabajar con grandes volúmenes de datos no estructurados (texto, imágenes, etc). • Identifica estructuras y relaciones que no son evidentes a simple vista. • Sirve como paso previo para modelos supervisados, definiendo etiquetas automáticas.	• Validación compleja: Al no existir una "respuesta correcta", validar los resultados requiere métricas adicionales como el índice de Silhouette (silueta). • Sensibilidad: Los resultados dependen críticamente del preprocesamiento (escalado de variables) y del método de distancia elegido. • Interpretación: El algoritmo no define el significado del grupo; el analista debe traducir la agrupación en información accionable.

COMPARACIÓN ENTRE ALGORITMOS

Característica	K-Means	DBSCAN	Clustering Jerárquico (Hierarchical clustering)
Fundamento	Basado en centroides (distancia a puntos medios)	Basado en densidad de puntos en el espacio	Estructura de árbol o dendrograma (aglomerativo/divisivo)
Número de Clústeres k	Requiere definirse previamente	No requiere definirse previamente	Se decide después visualizando el dendrograma
Forma de los Clústeres	Esféricos, similares tamaños.	Detecta formas arbitrarias y complejas	Arbitraria, basada en la jerarquía de fusiones
Sensibilidad ante Outliers	Muy sensible (distorsionan los centroides)	Robusto (clasifica puntos aislados como ruido)	Sensible a errores iniciales que se propagan en la jerarquía
Escalabilidad	Alta (eficiente para grandes datasets)	Media (baja rendimiento en alta dimensionalidad)	Baja (ineficiente en conjuntos de datos muy grandes)
Ejemplos de Casos Reales	Compresión de imágenes (reduciendo el número de colores) o segmentación de mercado donde se busca una división clara y balanceada de grupos.	Detección de anomalías y fraudes, separando el comportamiento normal de puntos aislados (ruido).	Preferido en biología y taxonomía, ya que permite visualizar relaciones evolutivas o funcionales complejas a través de su estructura multinivel.

LECCIÓN 3 - REDUCCIÓN DIMENSIONAL Y PREPROCESAMIENTO

DESCRIPCIÓN DEL DATASET


Se utilizo el dataset "Customer Segmentation" desde Kaggle de kaushiksuresh147, archivo Train.csv. El dataset cuenta con 8068 registros y 11 variables, de las cuales 6 presentan valores faltantes.

Este cuenta con las siguientes variables:


Variable	Tipo	Descripción y Valores Posibles
ID	Numérica	ID único del cliente (Entero único por fila) - eliminado antes del modelado
Gender	Categórica	Género del cliente (Male / Female)
Ever_Married	Categórica	¿Está el cliente casado? (Yes / No) - contiene nulos
Age	Numérica	Edad del cliente (18-85 anos)
Graduated	Categórica	Estudios universitarios completos (Yes / No) - contiene nulos
Profession	Categórica	Profesión del cliente (Artist, Doctor, Engineer, Entertainment, Executive, Healthcare, Homemaker, Lawyer, Marketing) - contiene nulos
Work_Experience	Numérica	Experiencia laboral en cantidad de años (0-14 años) - contiene nulos
Spending_Score	Categórica Ordinal	Nivel de gasto del cliente (Low < Average < High)
Family_Size	Numérica	Número de integrantes del hogar incluyendo al cliente (1-9 miembros) - contiene nulos
Var_1	Categórica	Categoría anónima para el cliente. Significado desconocido. (Cat_1 ... Cat_7.) - contiene nulos
Segmentation	Categórica	Categoría asignada en el problema original de Kaggle (A / B / C / D) - eliminado antes del modelado

PREPROCESAMIENTO

- Copia del dataset original para preservar datos crudos
- Exploración del Dataset




- Eliminación de columnas innecesarias: ID y Segmentation.
- Imputación de valores nulos: Se detectaron 1.582 valores nulos. Los cuales fueron imputados con la mediana para variables numéricas y la moda para variables categóricas (SimpleImputer).
- Identificar outliers con IQR: Se detectaron 354 outliers. Fueron eliminadas filas fuera del $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$ y quedamos con un dataset con 7.720 registros. Originalmente, eran 8.068.



- Pipeline Escalamiento y Codificación:
 - StandardScaler para variables numéricas.
 - OrdinalEncoder para variable Categórica Ordinal ('Spending_Score').
 - OneHotEncoder para variables nominales.
 - Quedamos con un dataset con 26 dimensiones.

REDUCCIÓN DE DIMENSIONALIDAD



PCA — ANÁLISIS DE COMPONENTES PRINCIPALES

PCA se usa como entrada para los algoritmos de clustering (K-Means, DBSCAN, Jerárquico), porque reduce dimensiones conservando la mayor varianza posible y es reproducible.

En este caso, se logró reducir a 2 componentes y se conserva el 43.8% de la información original del dataset. El gráfico muestra una nube densa, sin agrupaciones visibles, lo que indica que las diferencias entre clientes no se capturan bien en solo 2 dimensiones lineales. Sin embargo, es útil como primera aproximación visual.

T-SNE (T-DISTRIBUTED STOCHASTIC NEIGHBOR EMBEDDING)

t-SNE se usa exclusivamente para visualización de los resultados del clustering, ya que revela mejor la estructura local de los datos. Pero no puede usarse para transformar nuevos datos, ni como entrada a otros modelos.


El gráfico revela grupos sin fronteras nítidas entre ellos. Esto sugiere que los segmentos de clientes existen, pero con cierto grado de solapamiento, comportamiento esperable en datos reales de retail.

LECCIÓN 4 - APLICACIÓN PRACTICA DE CLUSTERIZACIÓN

ALGORITMO K-MEANS

SELECCIÓN DE K — MÉTODO DEL CODO

Se calculó la inercia para k entre 2 y 10. El cambio más notable de pendiente ocurre entre $k=4$ y $k=5$, sugiriendo $k=5$ como k óptimo.




COEFICIENTE DE SILUETA

Algoritmo	k	Coeficiente de Silueta
Método del Codo	5	0,1661
K óptimo	3	0,1960

Hay una discrepancia entre ambos métodos, lo cual es común cuando los datos no tienen clústeres perfectamente definidos. Las opciones son:

- Con $k=3$ se genera una mejor calidad de clustering según silueta. Grupos más compactos y separados, aunque sean menos.
- Con $k=5$, sugerido por el codo, se generan más segmentos. Esto permite estrategias de marketing más específicas.

Por lo que, a pesar de que $k=3$ es valor de silueta recomendado, en este caso, dado que la diferente entre los coeficientes es pequeña y el objetivo del análisis es segmentar clientes se elegirá $k=5$.




El solapamiento central entre naranja, verde y púrpura refleja que estos tres perfiles comparten características similares en las dimensiones capturadas por PCA. El clúster 3 (rojo) y el clúster 0 (azul) son los más separados del resto. El solapamiento es consistente con la silueta de 0,1660, ya que los grupos existen, pero con fronteras difusas.

ALGORITMO DBSCAN


eps	Clústeres	Ruido	Coefficiente de Silueta
1,4	160	1.292 (16,7%)	0,0879
1,45 (elegido)	2	484 (6.3%)	0,1623

El salto brusco que ocurre entre $\text{eps}=1.4$ (160 clústeres) y $\text{eps}=1.45$ (2 clústeres) confirma el problema de la maldición de la dimensionalidad. Como el dataset tiene 26 dimensiones, no hay una zona de transición suave como en datasets pequeños. Esto es una desventaja de este algoritmo.



DBSCAN no es el algoritmo más adecuado para este dataset, porque la alta dimensionalidad impide identificar diferencias de densidad significativas. Su aporte principal es la detección de 484 clientes atípicos.

ALGORITMO AGRUPAMIENTO JERÁRQUICO (HIERARCHICAL CLUSTERING)



El dendrograma con linkage Ward con corte en $y=60$ se identifican 5 grupos, confirmado con `fcluster(Z, t=60)`. Coincide con k sugerido por el método del codo.

k	Coficiente de Silueta
k=2	0,1525
k=3 (optimo estadístico)	0,1804
k=4	0,1388
k=5 (elegido)	0,1247
k=6	0,1281
k=7	0,1196

El máximo está en $k=3$ con 0,1804, igual que en K-Means Óptimo. Por lo que, en dos algoritmos distintos, K-Means y Jerárquico, indica que utilizar un $k = 3$ produce grupos de mejor calidad estadística. Pero $k = 5$ tiene el respaldo de tres fuentes distintas: método del codo ($k=5$), dendrograma ($k=5$) y los segmentos originales del dataset ($k=4$).

Adicionalmente, la diferencia de silueta entre $k=3$ y $k=5$ es 0.0557 (pequeña). Con una diferencia de 0.0557, la pérdida de calidad estadística se justifica.

Finalmente, al tener cinco perfiles de clientes ($k=5$) esto permite estrategias de marketing más granulares y diferenciadas.



INTERPRETACIÓN DE PERFILES POR CLÚSTER CON $K=5$:

Clúster	Perfil	Características
0	Mujeres Maduras Artistas, Gasto Bajo	Edad: 38.85 Experiencia: 7.35 Familia: 2.63 Spending: Low Género: Female Casada: Yes Graduada: Yes Profesión: Artist
1	Hombres Maduros Casados, Gasto Medio	Edad: 46.64 Experiencia: 0.87 Familia: 3.01 Spending: Average Género: Male Casado: Yes Graduado: Yes Profesión: Artist

Clúster	Perfil	Características
2	Jóvenes Solteros Sin Experiencia, Gasto Bajo	Edad: 26.99 Experiencia: 0.98 Familia: 3.84 Spending: Low Género: Male Casado: No Graduado: No Profesión: Healthcare
3	Adultos Mayores (hombres), Gasto Alto	Edad: 70.81 Experiencia: 0.68 Familia: 1.95 Spending: High Género: Male Casado: Yes Graduado: Yes Profesión: Lawyer
4	Mujeres Jóvenes Independientes, Gasto Bajo	Edad: 39.72 Experiencia: 0.90 Familia: 1.56 Spending: Low Género: Female Casada: No Graduada: Yes Profesión: Artist

LECCIÓN 5 - EVALUACIÓN E INFORME DE RESULTADOS

TABLA COMPARATIVA		
Algoritmo	Clústeres	Coeeficiente de Silueta
DBSCAN (eps=1.4)	160	0,0879
Jerárquico Ward (k=5 elegido)	5	0,1247
DBSCAN (eps=1.45 elegido)	2	0,1623
K-Means (k=5 elegido)	5	0,1661
Jerárquico Ward (k=3)	3	0,1804
K-Means (k=3 óptima silueta)	3	0,1960

Al comprar los resultados de los tres algoritmos se concluye que:

Sobre el número óptimo de clústeres:

- La silueta de K-Means y Jerárquico coinciden en que k=3 produce la mejor calidad estadística.
- El método del codo y el dendrograma coinciden en k=5 como mejor opción de negocio.
- DBSCAN confirma que los datos no tienen fronteras de densidad claras debido a la alta dimensionalidad (26 columnas). La maldición de la dimensionalidad impide que funcione bien.


Sobre los valores de silueta:

- Ningún algoritmo produce silueta > 0.50, lo cual es consistente con lo observado en t-SNE: grupos con solapamiento natural.

Decisión final: K-Means con k=5

- Consistente con método del codo y dendrograma.

- Mayor silueta entre las versiones con k=5
- Cinco segmentos de clientes para generar un marketing diferenciado.



Basado en los perfiles identificados por K-Means (k=5):

Clúster	Perfil	Estrategia Comercial
0	Mujeres Maduras Artistas, Gasto Bajo	Descuentos en arte y cultura. Programas de fidelización con beneficios acumulables.
1	Hombres Maduros Casados, Gasto Medio	Ofertas en productos para el hogar. Campañas de temporada y categorías premium.
2	Jóvenes Solteros Sin Experiencia, Gasto Bajo	Promociones de captación y primer pedido. Programas de referidos e incentivos digitales.
3	Adultos Mayores (hombres), Gasto Alto	Catálogo premium. Atención personalizada y programa VIP con beneficios exclusivos.
4	Mujeres Jóvenes Independientes, Gasto Bajo	Campañas en redes sociales. Suscripciones mensuales con descuento progresivo.

Acciones adicionales:

- Los 484 clientes identificados como ruido por DBSCAN representan perfiles atípicos. Estos podrían ser objeto de análisis individual para detectar oportunidades de nicho o comportamientos anómalos.
- Re-evaluar la segmentación cada 6 meses para detectar cambios en el comportamiento de compra.