


Clasificador Inteligente de Imágenes de Ropa

Proyecto Módulo 8: Implementación de Deep Learning para StyleNet



El Cuello de Botella en StyleNet



El crecimiento del catálogo ha superado la capacidad humana. El etiquetado manual actual genera retrasos logísticos y errores de categorización que impactan la experiencia del usuario.

Diseñar e implementar un prototipo funcional capaz de automatizar la clasificación de prendas con un alto nivel de exactitud, reemplazando la fricción manual con eficiencia algorítmica.

Dataset Fashion-MNIST

**Volumen de
Entrenamiento:**

60,000 imágenes

**Volumen de
Prueba:**

10,000 imágenes

Dimensiones:

Matrices de 28x28 píxeles

Formato:










Escala de grises (Tensores 1D/3D)

Categorías:

10 clases distintas (0-9)

Un entorno estandarizado perfecto para evaluar
y comparar arquitecturas de visión artificial.

Fashion-MNIST - Muestras de entrenamiento



Arquitectura de una Red Neuronal


Capa de Entrada

Recibe la matriz bruta de datos.

Capas Ocultas (El Perceptrón)

Aplican pesos (w) y sesgos (b) para capturar relaciones no lineales.


28x28
Input Grid



Output
(10 Nodes)


Backpropagation

El núcleo del aprendizaje. Calcula el gradiente del error y retropropaga el ajuste de pesos mediante descenso de gradiente para minimizar la función de pérdida (Loss).



Válvulas de Control: Funciones de Activación


Extracción de Características (ReLU)



$$\max(0, x)$$

Ubicada en las capas ocultas. Ignora valores negativos y activa las neuronas relevantes. Es computacionalmente eficiente y previene el desvanecimiento del gradiente en redes profundas.


Distribución de Probabilidad (Softmax)



$$e^{x_i} / \sum e^{x_j}$$



Ubicada en la capa de salida. Convierte los puntajes brutos de las 10 neuronas finales en **probabilidades porcentuales** que suman 100%. Define la predicción final (multiclase).

El Problema de la Estructura Espacial



El Hilo Deshilachado (Aplanado 1D)

La Red Densa (MLP) requiere aplanar la imagen, perdiendo la relación de vecindad entre píxeles (bordes, formas).



La Lupa Espacial (Filtros 2D)

La Red Convolutiva (CNN) escanea la imagen bidimensional intacta, reconociendo texturas locales independientemente de su posición.

Decisión Arquitectónica: MLP vs. CNN

—	Red Densa (MLP)	Red Convolutacional (CNN)
Tratamiento del Dato	Aplana 28×28 → vector de 784 valores	Trabaja en 2D (28×28×1), preserva estructura
Detección de Patrones	Trata cada píxel como independiente	Detecta bordes, texturas y formas
Eficiencia de Parámetros	Pierde la estructura espacial de la imagen	Comparte pesos → más eficiente

Selección Óptima para Visión Artificial: CNN

Framework elegido: Keras — API de alto nivel, simple y legible, ideal para prototipado rápido.

Modelo Base: Red Densa (MLP) y Sobreajuste

Arquitectura y Resultados

Pipeline: Input(784) -> Dense(128, ReLU) -> Dense(10, Softmax)
optimizer='adam' · lr=0.001 (default)
epochs=15 · batch_size=64
loss='categorical_crossentropy'

Parámetros Totales: 101,770



Accuracy Train: 92.11%

Accuracy Val: 89.22%

A partir de la época 8, la brecha entre el conjunto de entrenamiento y validación se amplía. La Loss de validación oscila.

Conclusión: brecha leve entre train y validación, el modelo mantiene buena capacidad de generalización.


MLP Simple – Evolución del entrenamiento



Afinando el Motor: Ajuste de Hiperparámetros

Learning Rate Alto (0.001): Pasos largos. Converge rápido pero puede resbalar/divergir.

Learning Rate Bajo (0.0001): Pasos cortos. Muy estable, evita el overfitting, pero requiere más épocas.



Configuración Optimizada:


Pipeline: Input(784) → Dense(128, relu) → Dense(10, softmax)
optimizer=Adam(learning_rate=0.0001)
epochs=15 · batch_size=128

Regularización: Dropout en capa oculta


Batch Size: Incrementar de 64 a 128 redujo el ruido en cada actualización, aportando estabilidad.

Resultado: La brecha de validación desapareció (Train: 87.62%, Val: 86.63%), pero a costa de velocidad bruta.


Accuracy - comparativa



Loss - comparativa



La Evolución de la Red Neuronal Convolutiva (CNN)



Capas Conv2D (32 y 64 filtros)	MaxPooling2D	Regularización
Extracción de características espaciales.	Reducción de dimensionalidad, conservando los patrones más fuertes.	Capa Dropout (0.5) que desactiva el 50% de las neuronas aleatoriamente para forzar la generalización estructural.

Nota de Eficiencia: Solo 34,826 parámetros totales (65% menos que el modelo MLP simple), demostrando una eficiencia arquitectónica superior.

Rendimiento Final: La CNN supera la prueba


Precisión MLP (Test)

88.74%


Precisión CNN (Test)

90.38%

Integridad del Entrenamiento: La CNN cerró con 90.89% (Train) y 91.25% (Val). La validación supera al entrenamiento, confirmando cero sobreajuste y una generalización excepcional en datos no vistos.



Diagnóstico de Errores: Los Límites Cognitivos



El Éxito (F1-Score 0.99)


Pantalones (975/1000 aciertos) y Zapatillas (980/1000). Forma altamente distintiva.

La Zona de Conflicto

La clase 6 (Camisa) es el talón de Aquiles (F1-Score 0.71). El modelo comete errores humanos. Confunde 148 Camisas con Remeras y 77 con Suéteres debido a su similitud visual extrema en formato de 28x28 píxeles.

Predicciones en Vivo: El Modelo en Acción

Predicciones CNN - Verde=Correcto | Rojo=Error



Contexto: Visualización directa del Test Set.

Observación: El modelo identifica instantáneamente texturas gruesas (**Abrigo**) y formas estructurales (**Bota**). Los **errores** (etiquetas en rojo) son contextualmente lógicos, demostrando un aprendizaje de características reales, no de ruido aleatorio.

Conclusiones e Impacto para StyleNet




Eficiencia Operativa

El cuello de botella manual ha sido resuelto. El modelo procesa matrices en milisegundos.



Precisión Robusta

La arquitectura CNN garantiza un +90% de exactitud en datos nuevos, optimizando el catálogo con un margen de error mínimo y predecible.



Escalabilidad (Keras)

Se entrega un prototipo funcional en Python/Keras, altamente modular y listo para ser empaquetado y desplegado en los servidores de producción de la compañía.