

# INFORME FINAL ABP 9: FUNDAMENTOS DE BIG DATA RETAIL ANALYTICS PIPELINE

**Autora:** Bernardita Ortega

**GitHub:**

[https://github.com/bernimof/TD-CsdeDatos/tree/main/M9\\_Fundamentos\\_de\\_Big\\_Data](https://github.com/bernimof/TD-CsdeDatos/tree/main/M9_Fundamentos_de_Big_Data)

**Dataset:** Brazilian E-Commerce Public Dataset by Olist.

**Tablas utilizadas:** olist\_orders\_dataset.csv , olist\_order\_items\_dataset.csv , olist\_order\_reviews\_dataset.csv y olist\_products\_dataset.csv

**Link:** <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

## SITUACIÓN INICIAL

**Unidad solicitante:** Departamento de Analítica y Machine Learning — RetailMax.

La empresa RetailMax maneja millones de transacciones diarias en su plataforma e-commerce, lo que genera grandes volúmenes de datos provenientes de compras, comportamiento de navegación, reseñas y calificaciones. Actualmente, el proceso de análisis es lento y fragmentado: los datos se almacenan en múltiples sistemas y los modelos de Machine Learning tradicionales no pueden escalar a la magnitud del dataset.

El área de analítica solicita desarrollar un pipeline de Big Data y Machine Learning escalable, capaz de:

1. Procesar datos estructurados y no estructurados en entornos distribuidos.
2. Ejecutar transformaciones masivas para generar métricas de negocio.
3. Entrenar y evaluar modelos de Machine Learning sobre grandes volúmenes de datos utilizando Spark MLlib.

## OBJETIVO

Diseñar e implementar un proyecto integral que comience con la ingesta y procesamiento de datos masivos, continúe con la transformación y análisis mediante Apache Spark, y finalice con la construcción de un modelo de Machine Learning escalable que permita clasificar usuarios y generar información accionable para el área de marketing.

### 1. LAS 5V DE BIG DATA

El concepto de Big Data está definido por un conjunto de características fundamentales conocidas como las 5V's. Estas dimensiones permiten comprender la complejidad y los desafíos asociados al manejo de datos masivos.

#### VOLUMEN

Hace referencia a la enorme cantidad de datos que se generan diariamente desde múltiples fuentes. Las organizaciones deben gestionar desde terabytes hasta petabytes de información, lo que requiere soluciones de almacenamiento escalables que los sistemas tradicionales no pueden manejar.

Ejemplo: En el sector financiero, los bancos procesan millones de transacciones diarias. Sin infraestructura distribuida como Hadoop o Spark, sería imposible almacenar y analizar ese volumen para detectar fraudes o calcular riesgos en tiempo real.

#### VELOCIDAD

Se refiere a la rapidez con la que los datos son generados, procesados y analizados. En la era digital, los datos fluyen de manera continua desde sensores, redes sociales, transacciones financieras y dispositivos móviles, exigiendo procesamiento casi en tiempo real.

Ejemplos: Netflix analiza el comportamiento de millones de usuarios en tiempo real para actualizar sus algoritmos de recomendación. En Chile, Transantiago genera datos en tiempo real desde miles de validaciones de tarjeta Bip! por hora.

#### VARIEDAD

Describe la diversidad de formatos y tipos de datos. A diferencia de los sistemas tradicionales que gestionan solo datos estructurados, en Big Data es común trabajar con datos no estructurados como textos, imágenes, videos y registros de sensores.

Ejemplos: Hospitales como el Mayo Clinic combinan historiales médicos estructurados, imágenes de radiografías y notas en texto libre para construir modelos predictivos de diagnóstico. El Ministerio de Salud combinó múltiples formatos de datos para construir el dashboard COVID-19.

#### VERACIDAD

Hace referencia a la calidad y confiabilidad de los datos. No todos los datos recopilados son precisos o relevantes — pueden contener inconsistencias, duplicados o información errónea. Es fundamental implementar mecanismos de limpieza y validación antes del análisis.

Ejemplo Chile: El SII recibe declaraciones de renta de millones de contribuyentes con datos inconsistentes o mal ingresados. Sin procesos de validación y limpieza, los cruces para detectar evasión tributaria generarían resultados incorrectos.

## VALOR

Es la dimensión más importante: de nada sirve recopilar grandes volúmenes de datos si no se puede extraer información útil. El objetivo final de cualquier estrategia Big Data es transformar los datos en conocimiento que genere valor para la organización.

Ejemplos: Amazon usa Big Data para optimizar su cadena logística. En Chile, Falabella analiza el comportamiento de compra de sus clientes a través de canales físicos, online y CMR para generar recomendaciones personalizadas y optimizar inventario.

## 2. FUENTES DE DATOS DEL PROYECTO

Se utilizará el dataset de Olist. Este es el mayor marketplace de Brasil, con más de 100.000 pedidos registrados entre 2016 y 2018. Su ecosistema de datos es un ejemplo real de Big Data. En este caso usaremos las siguientes cuatro fuentes de datos del proyecto:

| Archivo                         | Contenido                      | Columnas Clave                     |
|---------------------------------|--------------------------------|------------------------------------|
| olist_orders_dataset.csv        | Información general de pedidos | order_id, order_status, timestamps |
| olist_order_items_dataset.csv   | Detalle de ítems por pedido    | order_id, price, freight_value     |
| olist_order_reviews_dataset.csv | Puntuaciones y reseñas         | order_id, review_score             |
| olist_products_dataset.csv      | Catálogo y categorías          | product_id, product_category_name  |

## DIAGRAMA DE ARQUITECTURA



## LECCIÓN 2 - APACHE SPARK: INTRODUCCIÓN Y CONFIGURACIÓN

En el Jupyter Notebook *M9\_Fundamentos\_de\_Big\_Data\_v7.ipynb*, se configuró SparkContext y SparkSession con modo local[\*] para utilizar todos los cores disponibles. Los 4 archivos CSV se cargaron como RDDs para validar conectividad:

- olist\_orders\_dataset.csv — 99.441 líneas
- olist\_order\_items\_dataset.csv — 112.651 líneas

- olist\_order\_reviews\_dataset.csv — 104.720 líneas
- olist\_products\_dataset.csv — 32.952 líneas

### LECCIÓN 3 - ELEMENTOS BÁSICOS DE SPARK (RDD, TRANSFORMACIONES Y ACCIONES)

En el mismo Jupyter Notebook, se seleccionó el dataset de Ítems por Pedido (olist\_order\_items\_dataset.csv), ya que tiene columnas numéricas como order\_id, price y freight\_value que permiten practicar lo solicitado en esta lección.

#### TRANSFORMACIONES APLICADAS

- filter: ítems con precio > 200 BRL (13.374 ítems)
- map: (order\_id, precio\_total) donde total = price + freight.
- map: (seller\_id, price) para análisis por vendedor; solo precios para estadísticas.
- distinct: vendedores únicos.
- sortBy: ítems más caros primero.
- reduceByKey: ingresos totales por vendedor.
- flatMap: separa la fecha de envío en partes (fecha y hora).

#### ACCIONES EJECUTADAS

| Acción  | Resultados                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              |
|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| count   | 112.650 ítems totales, 13.374 con precio > 200 BRL, 3.095 vendedores únicos.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| mean    | precio promedio BRL 120.65                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              |
| stdev   | desviación estándar BRL 183.45 — gran dispersión en precios                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| collect | Primeros 5 ítems del RDD : [('00010242fe8c5a6d1ba2dd792cb16214', 1, '4244733e06e7ecb4970a6e2683c13e61', '48436dade18ac8b2bce089ec2a041202', '2017-09-19 09:45:35', 58.9, 13.29), ('00018f77f2f0320c557190d7a144bdd3', 1, 'e5f2d52b802189ee658865ca93d83a8f', 'dd7ddc04e1b6c2c614352b383efe2d36', '2017-05-03 11:05:13', 239.9, 19.93), ('000229ec398224ef6ca0657da4fc703e', 1, 'c777355d18b72b67abbeef9df44fd0fd', '5b51032eddd242adc84c38acab88f23d', '2018-01-18 14:48:30', 199.0, 17.87), ('00024acbcd0a6daa1e931b038114c75', 1, '7634da152a4610f1595efa32f14722fc', '9d7a1d34a5052409006425275ba1c2b4', '2018-08-15 10:10:18', 12.99, 12.79), ('00042b26cf59d7ce69dfabb4e55b4fd9', 1, 'ac6c3623068f30de03045865e4e10089', 'df560393f3a51e74553ab94004ba5c87', '2017-02-13 13:57:51', 199.9, 18.14)] |
| take    | Ejemplo de fechas separadas: ['2017-09-19', '09:45:35', '2017-05-03', '11:05:13', '2018-01-18', '14:48:30']                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
|         | Top 5 ítems más caros:<br>order_id=0812eb902a67711a1cb742b3cdaa65ae   \$6735.00   flete \$194.31<br>order_id=fefacc66af859508bf1a7934eab1e97f   \$6729.00   flete \$193.21<br>order_id=f5136e38d1a14a4dbd87dff67da82701   \$6499.00   flete \$227.66<br>order_id=a96610ab360d42a2e5335a3998b4718a   \$4799.00   flete \$151.34<br>order_id=199af31afc78c699f0dbf71fb178d4d4   \$4690.00   flete \$74.34                                                                                                                                                                                                                                                                                                                                                                                                 |

## JOBS, STAGES Y TASKS EN SPARK

Cada acción ejecutada sobre un RDD o DataFrame genera un Job en Spark. Cada Job se divide en Stages (etapas) separadas por shuffles de datos, y cada Stage se divide en Tasks que se ejecutan en paralelo en los distintos nodos del clúster.

Por ejemplo, al ejecutar `rdd_items.count()`:

- Spark genera 1 Job.
- El Job se divide en Stages según las transformaciones acumuladas.
- Cada Stage ejecuta Tasks en paralelo sobre las particiones del RDD.

```
1 # Linaje del RDD de ingresos por vendedor
2 print(ingresos_por_seller.toDebugString().decode())

(2) PythonRDD[57] at RDD at PythonRDD.scala:56 []
| MapPartitionsRDD[55] at mapPartitions at PythonRDD.scala:168 []
| ShuffledRDD[54] at partitionBy at NativeMethodAccessorImpl.java:0 []
+- (2) PairwiseRDD[53] at sortBy at /tmp/ipykernel_146/7310456.py:4 []
| PythonRDD[52] at sortBy at /tmp/ipykernel_146/7310456.py:4 []
| MapPartitionsRDD[49] at mapPartitions at PythonRDD.scala:168 []
| ShuffledRDD[48] at partitionBy at NativeMethodAccessorImpl.java:0 []
+- (2) PairwiseRDD[47] at reduceByKey at /tmp/ipykernel_146/7310456.py:3 []
| PythonRDD[46] at reduceByKey at /tmp/ipykernel_146/7310456.py:3 []
| PythonRDD[20] at RDD at PythonRDD.scala:56 []
|   CachedPartitions: 2; MemorySize: 11.0 MiB; DiskSize: 0.0 B
|   /content/olist_order_items_dataset.csv MapPartitionsRDD[10] at textFile at NativeMethodAccessorImpl.java:0 []
|   /content/olist_order_items_dataset.csv HadoopRDD[9] at textFile at NativeMethodAccessorImpl.java:0 []
```

En el linaje presentado anteriormente de `ingresos_por_seller` para obtener el top 10 de vendedores Spark ejecutó el siguiente flujo (de abajo hacia arriba) o generó un Job con múltiples Stages:

- Stage 1: leer CSV y aplicar cache
- Stage 2: extraer (`seller_id`, `price`) con `map`
- Stage 3: sumar por vendedor con `reduceByKey` (`shuffle`)
- Stage 4: ordenar y tomar top 10

Esto se puede visualizar en el Spark UI (<http://localhost:4040>) durante la ejecución, donde se pueden monitorear Jobs, Stages y Tasks en tiempo real. En este notebook usamos `local[*]` que simula un clúster usando todos los cores disponibles de la máquina local.

## LECCIÓN 4 - PROCESAMIENTO DE DATOS ESTRUCTURADOS (SPARK SQL Y DATAFRAMES)

### CONSTRUCCIÓN DE DATAFRAMES

Los RDDs se convirtieron a DataFrames con esquemas explícitos (`StructType`). Se aplicó limpieza de strings vacíos convirtiéndolos a null en columnas de tipo `StringType`.

Las reseñas se cargaron directamente con `spark.read.csv()` en lugar de parsear el RDD manualmente. Esto se debe a que el archivo contiene texto libre en los comentarios, con comas y

saltos de línea que rompen el parseo con `sc.textFile() + split(",")`. Evidencia: `rdd_reviews_raw.count()` devuelve 104.720 líneas, pero `spark.read.csv()` carga correctamente 104.162 registros.

## ANÁLISIS DE NULOS

| DataFrame   | Nulos relevantes                                                                                                    | Acción tomada                                                                |
|-------------|---------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| df_orders   | 160 en order_approved_at,<br>1.783 en<br>order_delivered_carrier_date,<br>2.965 en<br>order_delivered_customer_date | No afectan el pipeline — solo usamos<br>order_id, customer_id y order_status |
| df_items    | Sin nulos                                                                                                           | Filtrado en parseo RDD con <code>filter(lambda c:<br/>len(c) == 7)</code>    |
| df_reviews  | 2.236 en order_id, 2.380 en<br>review_score                                                                         | Filtrados antes del JOIN                                                     |
| df_products | 610 en product_category_name                                                                                        | product_id completo — left join mantiene<br>pedidos                          |

## CONSULTAS SQL — 12 CONSULTAS DE NEGOCIO

A continuación, se ejecutaron 12 consultas SQL sobre las dos vistas temporales registradas para generar métricas de negocio. Las dos vistas temporales son:

- `df_master (olist_master)`: una fila por pedido, para métricas generales y modelos machine learning.
- `df_items_detalle (olist_items_detalle)`: una fila por ítem, para análisis de productos y categorías.

El DataFrame maestro tiene 95.832 pedidos entregados. Ambos DataFrames se guardaron en formato Parquet para su uso en la Lección 5.

## VISIÓN GENERAL

- Consulta 1 Métricas generales: 95.832 pedidos, ticket promedio BRL 159.56, flete promedio BRL 22.76, satisfacción promedio 4.16/5, 1.14 ítems por pedido = la mayoría compra un solo producto.

| total_pedidos | ticket_promedio | flete_promedio | items_promedio | satisfaccion_prom |
|---------------|-----------------|----------------|----------------|-------------------|
| 95832         | 159.56          | 22.76          | 1.14           | 4.16              |

## ANÁLISIS DE VENTAS

- Consulta 2 Ventas por categoría: beleza\_saude lidera con BRL 1.258.681, seguida por relorios\_presentes (ticket más alto BRL 201).

| categoria            | pedidos | ventas_totales | ticket_prom |
|----------------------|---------|----------------|-------------|
| beleza_saude         | 8836    | 1258681.34     | 130.16      |
| relojos_presentes    | 5624    | 1205005.68     | 201.14      |
| cama_mesa_banho      | 9417    | 1036988.68     | 93.3        |
| esporte_lazer        | 7720    | 988048.97      | 114.34      |
| informatica_acess... | 6689    | 911954.32      | 116.51      |
| moveis_decoracao     | 6449    | 729762.49      | 87.56       |
| cool_stuff           | 3632    | 635290.85      | 167.36      |
| utilidades_domest... | 5884    | 632248.66      | 90.79       |
| automotivo           | 3897    | 592720.11      | 139.96      |
| ferramentas_jardim   | 3518    | 485256.46      | 111.63      |

- Consulta 3 Top 10 categorías por ticket: pcs lidera con BRL 1.098 por ítem (nichos de alto precio, no de alto volumen).

| categoria            | pedidos | ticket_prom |
|----------------------|---------|-------------|
| pcs                  | 203     | 1098.34     |
| portateis_casa_fo... | 76      | 624.29      |
| eletrodomesticos_2   | 238     | 476.12      |
| agro_industria_e...  | 212     | 342.12      |
| instrumentos_musi... | 680     | 281.62      |
| eletroportateis      | 679     | 280.78      |
| portateis_cozinha... | 15      | 264.57      |
| telefonica_fixa      | 264     | 225.69      |
| construcao_ferram... | 194     | 208.99      |
| relojos_presentes    | 5991    | 201.14      |

- Consulta 4 Top 10 pedidos por valor total: Los pedidos más caros con varios ítems tienden a tener review\_score 1, mientras que los de un solo ítem caro tienen review\_score 5.

| order_id             | n_items | revenue | freight_total | order_total | review_score |
|----------------------|---------|---------|---------------|-------------|--------------|
| 03caa2c082116e1d3... | 8       | 13440.0 | 224.08        | 13664.08    | 1.0          |
| 736e1922ae60d0d6a... | 4       | 7160.0  | 114.88        | 7274.88     | 1.0          |
| 0812eb902a67711a1... | 1       | 6735.0  | 194.31        | 6929.31     | 5.0          |
| f5136e38d1a14a4db... | 1       | 6499.0  | 227.66        | 6726.66     | 5.0          |
| 2cc9089445046817a... | 6       | 5934.6  | 146.94        | 6081.54     | 1.0          |
| a96610ab360d42a2e... | 1       | 4799.0  | 151.34        | 4950.34     | 5.0          |
| 199af31afc78c699f... | 1       | 4690.0  | 74.34         | 4764.34     | 4.0          |
| 8dbc85d1447242f3b... | 1       | 4590.0  | 91.78         | 4681.78     | 5.0          |
| 426a9742b533fc6fe... | 1       | 4399.87 | 113.45        | 4513.32     | 5.0          |
| d2f270487125ddc41... | 2       | 4400.0  | 45.5          | 4445.5      | 5.0          |

- Consulta 5 Top 10 productos más vendidos: moveis\_decoracao y ferramentas\_jardim dominan el top 10.

| product_id           | categoria            | veces_vendido | precio_prom |
|----------------------|----------------------|---------------|-------------|
| aca2eb7d00ea1a7b8... | moveis_decoracao     | 527           | 71.36       |
| 99a4788cb24856965... | cama_mesa_banho      | 488           | 88.17       |
| 422879e10f4668299... | ferramentas_jardim   | 484           | 54.91       |
| 389d119b48cf3043d... | ferramentas_jardim   | 392           | 54.7        |
| 368c6c730842d7801... | ferramentas_jardim   | 388           | 54.27       |
| 53759a2ecddad2bb8... | ferramentas_jardim   | 373           | 54.66       |
| d1c427060a0f73f6b... | informatica_acess... | 343           | 137.65      |
| 53b36df67ebb7c415... | relogios_presentes   | 323           | 116.67      |
| 154e7e31ebfa09220... | beleza_saude         | 281           | 22.51       |
| 3dd2a17168ec895c7... | informatica_acess... | 274           | 149.94      |


- Consulta 6 Top 10 productos mejor evaluados (mínimo 10 pedidos): Los productos mejor evaluados tienen score perfecto (5.0) con mínimo 10 pedidos. Pertenecen principalmente a categorías de esporte\_lazer, moveis\_decoracao y beleza\_saude. El producto de esporte\_lazer con 14 pedidos es el más representativo del top por volumen.

| product_id           | categoria            | pedidos | satisfaccion_prom |
|----------------------|----------------------|---------|-------------------|
| 6ee7217ab647f3c2b... | moveis_decoracao     | 11      | 5.0               |
| f6ce2f79a280fa3c1... | eletroportateis      | 10      | 5.0               |
| 59c1840441f4df065... | fashion_bolsas_e...  | 11      | 5.0               |
| 8173ca41cdb176462... | esporte_lazer        | 14      | 5.0               |
| 0e839be47c2dc028c... | moveis_decoracao     | 10      | 5.0               |
| 36038dae78cc227e4... | esporte_lazer        | 10      | 5.0               |
| b9ee7519d0187d238... | esporte_lazer        | 10      | 5.0               |
| 2722b7e5f68e776d1... | beleza_saude         | 13      | 5.0               |
| 8b6ed41158b194711... | esporte_lazer        | 14      | 5.0               |
| 2ced45a3059cbb128... | informatica_acess... | 11      | 5.0               |

## ANÁLISIS DE SATISFACCIÓN


- Consulta 7 Pedidos con alta vs baja satisfacción del cliente: 75.626 pedidos con alta satisfacción (79%) vs 20.206 con baja (21%). Compras más caras y flete mayor generan más insatisfacción.

| satisfaccion | cantidad | ticket_prom | flete_prom | items_prom |
|--------------|----------|-------------|------------|------------|
| Alta (>=4)   | 75626    | 155.88      | 21.87      | 1.11       |
| Baja (<4)    | 20206    | 173.36      | 26.09      | 1.26       |



- Consulta 8 Satisfacción promedio por categoría de producto: Las categorías con mayor satisfacción son cds\_dvds\_musicais (4.64), fashion\_roupa\_infantil (4.50) y livros\_interesse\_geral (4.45). Las categorías de libros aparecen frecuentemente en el top, lo que sugiere que los clientes que compran libros tienden a quedar más satisfechos.

| categoria            | cantidad | satisfaccion_prom | precio_prom |
|----------------------|----------|-------------------|-------------|
| cds_dvds_musicais    | 14       | 4.64              | 52.14       |
| fashion_roupa_inf... | 8        | 4.5               | 71.23       |
| livros_interesse_... | 553      | 4.45              | 84.73       |
| construcao_ferram... | 103      | 4.44              | 154.41      |
| flores               | 33       | 4.42              | 33.64       |
| livros_importados    | 60       | 4.4               | 77.33       |
| livros_tecnicos      | 267      | 4.36              | 71.52       |
| malas_acessorios     | 1092     | 4.32              | 128.6       |
| alimentos_bebidas    | 278      | 4.31              | 54.6        |
| portateis_casa_fo... | 76       | 4.3               | 624.29      |



- Consulta 9 Precio vs Satisfacción: se observa una tendencia que a mayor precio, menor satisfacción promedio (4.25 para < BRL 50, 4.00 para > BRL 500)

| rango_precio    | pedidos | satisfaccion_prom |
|-----------------|---------|-------------------|
| Bajo (< 50)     | 16378   | 4.25              |
| Medio (50-150)  | 48417   | 4.18              |
| Alto (150-500)  | 27005   | 4.08              |
| Premium (> 500) | 4032    | 4.0               |

- Consulta 10 Relación entre flete y satisfacción por rango de flete: se observa que a mayor costo de envío o flete, menor satisfacción (4.35 para < BRL 10, 3.85 para > BRL 50)

| rango_flete     | pedidos | satisfaccion_prom |
|-----------------|---------|-------------------|
| Bajo (< 10)     | 11013   | 4.35              |
| Medio (10-25)   | 61948   | 4.21              |
| Alto (25-50)    | 16822   | 3.96              |
| Muy alto (> 50) | 6049    | 3.85              |

## ANÁLISIS DE PEDIDOS

- Consulta 11 Pedidos con flete mayor al 30% del valor total: 19.700 pedidos con satisfacción promedio 4.11 vs 4.16 general

| pedidos_flete_alto | satisfaccion_prom |
|--------------------|-------------------|
| 19700              | 4.11              |

- Consulta 12 Pedidos con múltiples ítems vs ítem único: Los pedidos con múltiples ítems tienen menor satisfacción y mayor valor, probablemente porque son más complejos de entregar y generan más expectativas.

| tipo_pedido     | cantidad | satisfaccion_prom | ticket_prom |
|-----------------|----------|-------------------|-------------|
| Múltiples ítems | 9528     | 3.63              | 248.26      |
| Un ítem         | 86304    | 4.21              | 149.77      |

## LECCIÓN 5 - INTRODUCCIÓN A MACHINE LEARNING ESCALABLE (SPARK ML LIB)

Los DataFrames procesados se cargaron desde los archivos Parquet generados en la Lección 4. Se enriqueció df\_master con la categoría de producto desde df\_items\_detalle.

### MODELO SUPERVISADO — REGRESIÓN LOGÍSTICA: PARA CLASIFICAR PEDIDOS SATISFECHOS VS INSATISFECHOS.

Se construyó un modelo para clasificar pedidos en satisfacción alta (review\_score >= 4) vs baja. La variable target satisfaccion\_alta tiene un desbalance: 79% satisfechos vs 21% insatisfechos.

## FEATURE ENGINEERING

- StringIndexer: convierte product\_category\_name en índice numérico.
- Target encoding: promedio de review\_score por categoría — análisis exploratorio (excluido del modelo para evitar leakage con el target).
- VectorAssembler: features = [n\_items, revenue, freight\_total]
- StandardScaler: escalamiento de features (ajustado solo con train para evitar leakage).
- Split train/test 70/30 con seed=42 para reproducibilidad.

## COMPARACIÓN DE MODELOS

Se compararon 4 enfoques para manejar el desbalance de clases:

| Métrica                  | Original    | Sobremuestreo  | ClassWeight    | Umbral 0.3   |
|--------------------------|-------------|----------------|----------------|--------------|
| Accuracy                 | 78.75%      | 72.40%         | 72.25%         | 78.23%       |
| F1-score                 | 0.6991      | 0.7112         | 0.7104         | 0.7104       |
| Insatisfechos detectados | 67 de 6.039 | 1.449 de 6.039 | 1.458 de 6.039 | 314 de 6.039 |

Al comparar los resultados de los tres algoritmos se concluye que los modelos con sobremuestreo y classWeight detectan significativamente más clientes insatisfechos a costa de una menor accuracy. El ajuste de umbral ofrece un punto medio, ya que detecta 314 insatisfechos manteniendo una accuracy de 78.23%. El modelo original tiene la mejor accuracy, pero es casi inútil para el objetivo de negocio de identificar clientes insatisfechos para intervenir.

**Modelo elegido: Sobremuestreo.** Detecta 1.449 clientes insatisfechos vs solo 67 del modelo original (21 veces más). Lo que lo hace significativamente más útil para intervención de marketing y postventa, a pesar de una menor accuracy global (72.40%).

## MODELO NO SUPERVISADO — K-MEANS: PARA SEGMENTAR CLIENTES/PEDIDOS SEGÚN COMPORTAMIENTO DE COMPRA.

Se segmentaron 95.832 usuarios únicos según comportamiento de compra. Se observó que casi todos los clientes tienen exactamente 1 pedido, lo que indica que la segmentación refleja perfiles de compra más que trayectorias recurrentes.

## COMPARACIÓN DE VERSIONES K-MEANS

Se evaluaron 3 versiones con distintos conjuntos de features:


| Métrica               | V1 (4 variables)                                                      | V2 (Económicas)                   | V3 (Experiencia)                     |
|-----------------------|-----------------------------------------------------------------------|-----------------------------------|--------------------------------------|
| Features              | n_pedidos,<br>tasa_satisfaccion,<br>gasto_promedio,<br>flete_promedio | gasto_promedio,<br>flete_promedio | tasa_satisfaccion,<br>gasto_promedio |
| Silhouette            | 0.7174                                                                | 0.8762                            | 0.8019                               |
| Segmento Mayor        | 72.510 usuarios                                                       | 88.797 usuarios                   | 73.579 usuarios                      |
| Segmento insatisfecho | 19.200 (sat 1.93)                                                     | No aparece                        | 19.652 (sat 1.93)                    |
| Segmento premium      | 4.122 (gasto BRL 831)                                                 | 1.594 (gasto BRL 1.331)           | 2.601 (gasto BRL 1.115)              |

**Modelo elegido: V3 (tasa\_satisfaccion + gasto\_promedio).** V2 tiene el mejor Silhouette (0.8762), pero pierde el segmento de insatisfechos. V3 combina satisfacción y gasto con buen Silhouette (0.8019) y mantiene los 3 segmentos accionables.

#### PERFIL DE SEGMENTOS — MODELO FINAL V3

| Segmento      | Usuarios | Satisfacción | Gasto BRL | Estrategia                          |
|---------------|----------|--------------|-----------|-------------------------------------|
| Satisfechos   | 73.579   | 4.75         | 129       | Fidelización y recompra             |
| Insatisfechos | 19.652   | 1.93         | 144       | Recuperación y atención prioritaria |
| Premium       | 2.601    | 4.15         | 1.115     | Programa VIP exclusivo              |

**Perfil de Clústers — K-Means V3 (Modelo Final)**



*Visualización del perfil de gasto, satisfacción y flete para los 3 segmentos de clientes identificados*

## REPORTE FINAL

RetailMax procesó 95.832 pedidos entregados del marketplace Olist usando un pipeline completo de Big Data con Apache Spark.

### HALLAZGOS PRINCIPALES

#### SATISFACCIÓN DEL CLIENTE

- El 79% de los clientes tiene alta satisfacción (score  $\geq 4$ ).
- El flete alto ( $>30\%$  del valor total) se asocia con menor satisfacción.
- Los pedidos con múltiples ítems tienen menor satisfacción (3.63 vs 4.21).
- El ticket alto y el flete elevado tienden a asociarse con menor satisfacción.

#### CATEGORÍAS DE PRODUCTO

- Las categorías con mayor satisfacción son: cds\_dvds\_musicais, fashion\_roupa\_infantil y livros\_interesse\_geral.
- Las categorías con mayor venta no coinciden necesariamente con las de mayor satisfacción.

#### MODELO SUPERVISADO — REGRESIÓN LOGÍSTICA: PARA CLASIFICAR PEDIDOS SATISFECHOS VS INSATISFECHOS.

- Accuracy: 72.40% | F1-score: 0.7112 (modelo con sobremuestreo)
- Se estudiaron 3 estrategias para corregir el desbalance del dataset: Sobremuestreo, ClassWeight y ajuste de umbral a 0.3.
- Se seleccionó el sobremuestreo, porque detecta 1.449 clientes insatisfechos vs solo 67 del modelo original.

#### MODELO NO SUPERVISADO — K-MEANS: PARA SEGMENTAR CLIENTES/PEDIDOS SEGÚN COMPORTAMIENTO DE COMPRA.

- Se compararon 3 versiones del modelo con distintas features.
- Se eligió V3 (tasa\_satisfaccion + gasto\_promedio) por Silhouette 0.8019 y presencia del segmento insatisfecho.
- Resultado de Perfiles de Segmentación de Clientes:
  - Segmento Satisfechos (73.579 usuarios): satisfacción 4.75, gasto BRL 129.
  - Segmento Premium (2.601 usuarios): gasto BRL 1.115, satisfacción 4.15.
  - Segmento Insatisfechos (19.652 usuarios): satisfacción 1.93, gasto BRL 144.

### RECOMENDACIONES PARA MARKETING

- i. Reducir el costo de flete para pedidos con múltiples ítems.
- ii. Crear programa de fidelización para los 73.579 clientes Satisfechos.
- iii. Implementar atención prioritaria para los 19.652 clientes Insatisfechos.
- iv. Desarrollar programa VIP para los 2.601 clientes Premium.